



## Pontifícia Universidade Católica do Paraná

### Plano de Ensino

<b>Escola/ Câmpus:</b>	Escola Politécnica - Curitiba		
<b>Curso:</b>	Bacharelado em Ciência da Computação	<b>Ano/Sem:</b>	2023/1
<b>Código/Nome da disciplina:</b>	Machine Learning		
<b>Carga Horária:</b>	80 h/a		
<b>Requisitos:</b>	Não há.		
<b>Créditos:</b>	4	<b>Período:</b>	5º
<b>Professor Responsável:</b>	André Gustavo Hochuli		
	<b>Turma:</b>	U	

### 1. Ementa:

A disciplina de *Machine Learning* é ofertada no curso de Ciência da Computação. Nela, os estudantes aprendem inicialmente a identificar as diferentes abordagens de aprendizagem de máquina e suas principais tarefas, selecionando a mais adequada à solução do problema em mãos. Ao término, os estudantes são capazes de defender os resultados obtidos a partir da aplicação das técnicas estudadas, com base em métricas de avaliação de desempenho e análise de erro, empregando adequada argumentação técnica.

### 2. Relação com disciplinas precedentes e posteriores

- Disciplinas anteriores :
  - Raciocínio Algorítmico
  - Programação Orientada a Objetos
  - Banco de Dados
  - Resolução de Problemas Estruturados em Computação
- Disciplinas posteriores:
  - Segurança de Sistemas
  - Segurança e Privacidade num Mundo Digital

### 3. Temas de estudo

Abaixo são apresentados os principais temas de estudo da disciplina, seguidos de seus respectivos tópicos teóricos e práticos.

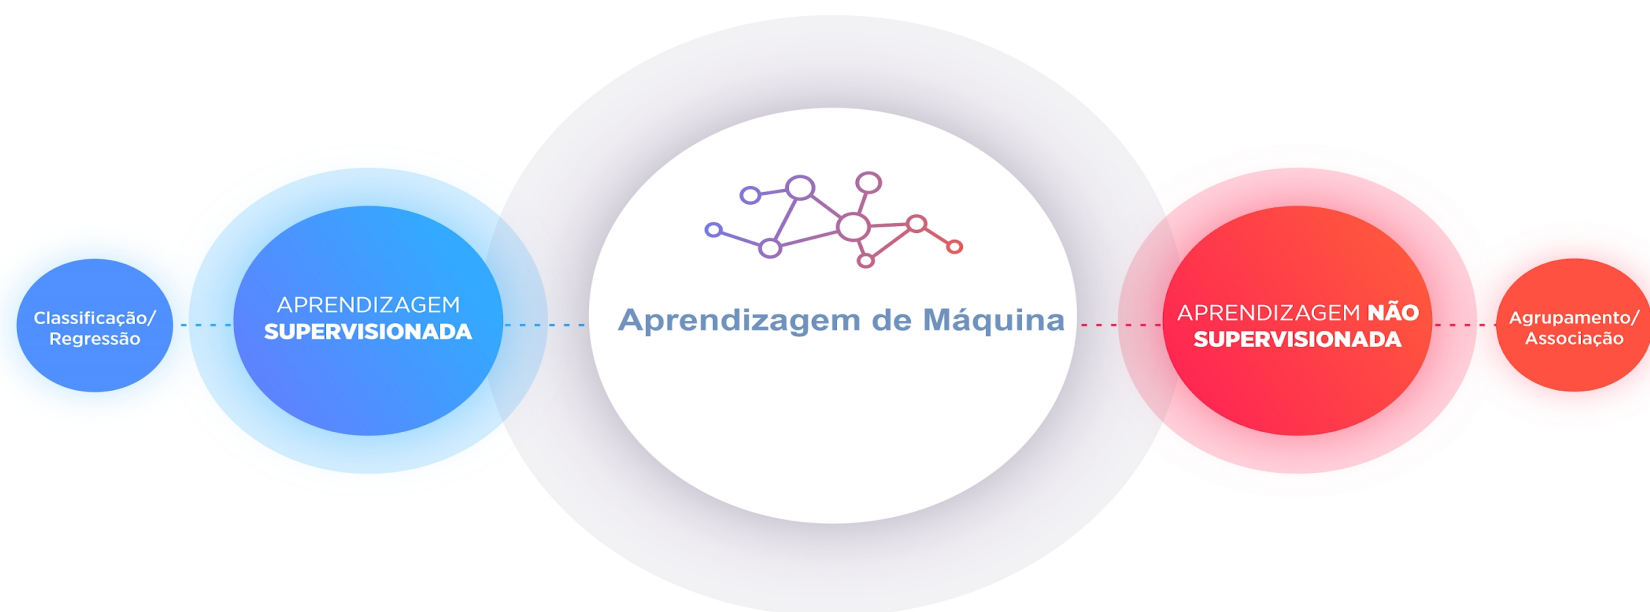
- (TE1): Introdução à aprendizagem de máquina: Definição, Terminologia e Aplicações.
- (TE2): Abordagens de aprendizagem de máquina (supervisionada, semi-supervisionada, não supervisionada e por reforço) e suas principais tarefas: classificação, regressão e agrupamento.
- (TE3): Aprendizagem não supervisionada: conceitos básicos (clusters, centroids), a tarefa de agrupamento, métricas de avaliação (dispersão e índice silhueta). Agrupamento usando K-médias.
- (TE4): Aprendizagem supervisionada: árvores de decisão e de regressão, técnica baseada em instâncias (K-vizinhos mais próximos), técnica Bayesiana (Naive Bayes).
- (TE5): Aprendizagem supervisionada: Redes Neurais Artificiais (MLP, Multi Layer Perceptron), Máquinas de Vetor de Suporte (SVM). Fusão de Classificadores. Modelos Profundos. Redes Recorrentes.
- (TE6) Avaliação dos resultados de diferentes técnicas para um dado problema: protocolo experimental robusto, uso de métricas de avaliação de desempenho adequadas, análise de erros.

### 4. Resultados de Aprendizagem

<b>Competência A</b> - Resolver problemas complexos não estruturados de solução algorítmica, considerando limites da computação, preceitos éticos e legais, de forma autônoma, crítica e inovadora.	
<b>Elemento de competência A1</b> - Identificar as soluções algorítmicas viáveis para problemas complexos e não estruturados.	
<b>RA1:</b> Identificar, corretamente, abordagens de aprendizagem de máquina supervisionada e não supervisionada e respectivas tarefas em diferentes situações de contexto real.	TE1, TE2
<b>Elemento de competência A2</b> - Selecionar algoritmos apropriados para problemas complexos e não estruturados.	
<b>RA2:</b> Selecionar a técnica de aprendizagem de máquina adequada à solução	TE3, TE4, TE5

do problema.	
Competência A - Resolver problemas complexos não estruturados de solução algorítmica, considerando limites da computação, preceitos éticos e legais, de forma autônoma, crítica e inovadora.	
<b>Elemento de competência A3</b> - Criar soluções tecnológicas eficientes para dados estruturados e não estruturados.	
<b>RA3:</b> Defender resultados da técnica de aprendizagem de máquina selecionada, com base em análise de erros e identificando vantagens e desvantagens.	TE6

## 5. Mapa Mental



## 6. Metodologia e Avaliação

Os resultados de aprendizagem desta disciplina serão trabalhados de acordo com a Tabela 1 - Alinhamento Construtivo. Nesta tabela, os resultados de aprendizagem (RAs) são relacionados com os seus respectivos indicadores de desempenho (IDs), os métodos utilizados para a apresentação conceitual e prática dos conteúdos, assim como os processos de avaliação via metodologias diagnósticas, formativas e somativas; a serem realizadas, sempre visando feedback rápido e efetivo para os estudantes.

**Avaliações diagnósticas:** atividades com objetivo de acompanhar o aprendizado dos temas discutidos até o momento visando feedback imediato e de forma coletiva. A sugestão aqui é utilizar métodos como a linha da vida para engajar os estudantes a responder, mesmo que de forma não verbal, questões relacionadas ao conteúdo ministrado, permitindo ao professor elucidar conceitos que possivelmente estejam causando dúvidas e que os estudantes se auto-avaliem e identifiquem tópicos a serem verificados antes das avaliações somativas.

**Avaliações formativas:** atividades com enfoque prático que objetiva, por meio do trabalho em equipe, aplicar os conceitos ministrados pelo professor em problemas do mundo real. Estas avaliações permitem ao professor prover feedback aos alunos durante a própria aula, ainda de forma coletiva, mas focada em grupos menores de estudantes. Este tipo de atividade também permitirá que avaliação por pares seja realizada, onde equipes validem os trabalhos realizados pelas demais.

**Avaliações somativas:** atividades com o objetivo de quantificar a performance dos estudantes, de forma individual, nos conceitos teóricos e práticos que envolvem a disciplina. Sugere-se aqui a aplicação de avaliações no formato de provas. O feedback para este tipo de atividade será realizado de forma colaborativa, no sentido de que o professor apresentará a resposta para todas as questões da avaliação para todos os estudantes, seguido por um feedback individual para cada estudante. Objetiva-se realizar a devolutiva destas avaliações em um prazo de uma a duas semanas após sua realização.

Tabela 1 - Alinhamento Construtivo

Resultado de aprendizagem	Indicadores de desempenho	Processos de avaliação	Métodos ou técnicas empregados
<b>RA1:</b> Identificar, corretamente, abordagens de aprendizagem de máquina supervisionada e não	ID1.1: Diferencia abordagem de aprendizagem de máquina supervisionada de abordagem não	<b>Avaliação diagnóstica:</b> resolução de exercícios com cunho conceitual-teórico durante as aulas. <u>Feedback:</u> coletivo e imediato, durante as aulas.	Simulação realística (PBL)

supervisionada e respectivas tarefas em diferentes situações de contexto real.	<p>supervisionada em diferentes situações de contexto real.</p> <p>ID1.2: Identifica tarefas de classificação, regressão e agrupamento conforme a abordagem de aprendizagem de máquina.</p>	<p><b>Avaliação formativa:</b> resolução de exercícios com simulação realística. <u>Feedback:</u> coletivo, em sala de aula.</p> <p><b>Avaliação somativa:</b> Questões em provas escritas também com temática de simulação realística em formato de PBL. <u>Feedback:</u> individual. <u>Recuperação:</u> ocorrerá no formato de trabalhos extraclasse, de acordo com a necessidade de cada estudante.</p>	Aula expositiva
<b>RA2:</b> Selecionar a técnica de aprendizagem de máquina adequada à solução do problema.	<p>ID2.1: Diferencia técnicas de aprendizagem de máquina supervisionada e não supervisionada.</p> <p>ID2.2: Seleciona a técnica de aprendizagem de máquina adequada à solução do problema, com base em protocolo experimental.</p>	<p><b>Avaliação diagnóstica:</b> resolução de exercícios com cunho conceitual-teórico durante as aulas. <u>Feedback:</u> coletivo e imediato, durante as aulas.</p> <p><b>Avaliação formativa:</b> resolução de exercícios com simulação realística. <u>Feedback:</u> coletivo em sala de aula.</p> <p><b>Avaliação somativa:</b> trabalho de implementação de projeto realizado em equipes. <u>Feedback:</u> coletivo, para a equipe, com vistoria de código individualizada. <u>Recuperação:</u> ocorrerá no formato de trabalhos extraclasse, de acordo com a necessidade de cada estudante.</p> <p><b>Avaliação somativa:</b> questões em provas escritas. <u>Feedback:</u> individual.</p>	<p>PBL</p> <p>Peer Instruction</p> <p>Aula expositiva</p>

		<u>Recuperação</u> : ocorrerá na semana de recuperação.	
<b>RA3:</b> Aplicar a técnica de aprendizagem de máquina selecionada, avaliando com base em análise de erros e identificando vantagens e desvantagens.	<p>ID3.1: Aplica a técnica de aprendizagem de máquina.</p> <p>ID3.2: Avalia a técnica aplicada a partir de um protocolo experimental robusto justificando os resultados observados.</p>	<p><b>Avaliação diagnóstica:</b> resolução de exercícios com cunho conceitual-teórico durante as aulas.  <u>Feedback</u>: coletivo e imediato, durante as aulas.</p> <p><b>Avaliação formativa:</b> resolução de exercícios com simulação realística.  <u>Feedback</u>: coletivo em sala de aula.</p> <p><b>Avaliação somativa:</b> trabalho de implementação de projeto realizado em equipes.  <u>Feedback</u>: coletivo, para a equipe, com vistoria de código individualizada.  <u>Recuperação</u>: ocorrerá no formato de trabalhos extraclasse, de acordo com a necessidade de cada estudante.</p> <p><b>Avaliação somativa:</b> questões em provas escritas.  <u>Feedback</u>: individual.  <u>Recuperação</u>: ocorrerá na semana de recuperação.</p>	<p>PBL</p> <p>Peer Instruction</p> <p>Aula expositiva</p>

Para **aprovação** nesta disciplina, assume-se os seguintes critérios:

- O estudante deverá obter uma nota média maior ou igual a 7,0 (sete) em **todos** os RAs.
- Caso o estudante **não** atinja a nota necessária em um RA durante uma das atividades propostas, haverá uma oportunidade de recuperação ainda durante o semestre. A única ressalva é a última prova, por questões de cronograma.
- Caso, mesmo após a recuperação ofertada durante o semestre, o estudante **não** atinja a nota mínima esperada em um ou mais RAs, será oportunizada uma semana de Recuperação, onde o estudante terá a oportunidade de recuperar os resultados não atingidos por meio de atividades específicas.

- O estudante poderá recuperar, **no máximo**, nota 7,0 (sete) para o RA em questão. Isso se dá independentemente se a recuperação ocorre durante ou no final do semestre.
- Caso o estudante falhe ao atingir a nota mínima em **todos** os RAs necessários, mesmo após a semana de recuperação, o estudante será considerado **reprovado** e deverá cursar novamente a disciplina.
- O mapeamento entre cada RA, ID e os seus respectivos pesos é fornecido na Tabela 2.

Tabela 2 - Pesos dos RAs e IDs em cada Avaliação					
Resultado de Aprendizagem (RA)	Indicador de Desempenho (ID)	Avaliação somativa Trabalhos* (Peso no RA)	Avaliação somativa Prova 01 (Peso no RA)	Avaliação somativa Prova 02 (Peso no RA)	Nota do RA (0 a 10)
RA1	ID1.1		100%		Soma das notas obtidas nos ID1.1 e ID1.2
	ID1.2				
RA2	ID2.1	33,3%	33,3%	33,3%	Soma das notas obtidas nos ID2.1 e ID2.2
	ID2.2				
RA3	ID3.1	40%	10%	40%	Soma das notas obtidas nos ID3.1 e ID3.2
	ID3.2				

\* todos os trabalhos apresentam a mesma distribuição de pesos por R.A

- A nota final do estudante na disciplina é calculada de acordo com a média das notas obtidas em cada um dos RAs, conforme a equação abaixo:

$$Nota\ Final = (RA_1 + RA_2 + RA_3) / 3$$

## 7. Cronograma de Atividades

O cronograma previsto para a realização desta disciplina é fornecido abaixo. Mudanças no cronograma poderão ocorrer de acordo com o andamento da disciplina.

Data	RAs	Atividades Pedagógicas	Carga	
			Em aula/ TDE	horária
06/03/23	1	Apresentação do plano de ensino, ementa, formato de avaliação. Apresentação dos TDEs.	Em aula	4h
09/03/23		Introdução a Aprendizagem de Máquina (AM). Conceitos Básicos. Aplicações.		
13/03/23	1,2	Técnicas supervisionadas. Tarefas de classificação/regressão. Abordagem Baseada em	Em aula	4h
16/03/23		Instâncias (KNN) e Árvores de Decisão. Exercícios		
20/03/23	1,2	Técnicas supervisionadas. Tarefas de classificação. Abordagem Bayesiana (Naive Bayes).	Em aula	4h
23/03/23		Exercícios		
27/03/23	1,2	Técnicas supervisionadas. Classificação/Regressão. Máquinas de Vetor de Suporte (SVM).	Em aula	4h
30/03/23		Exercícios		
03/04/23	1,2,3	Técnicas supervisionadas. Classificação/Regressão. Redes Neurais Artificiais.	Em aula	4h
06/04/23		Avaliação Formativa: Análise Comparativa		
10/04/23	1,2,3	Avaliação Somativa 01: Trabalho Prático em Grupo (Implementação KNN/Naive Bayes)	Em aula / TDE	4h / 8h
13/04/23				
17/04/23	1,2	Avaliação Somativa 02: Prova Individual	Em aula	4h
20/04/23		Devolutiva Avaliações		
24/04/23	1,2,3	Pool (ensemble) homogêneo e heterogêneo. Regras de Fusão. Algoritmos de Bagging, Boosting, Random Forest. Exercícios	Em aula	4h
27/04/23				
01/05/23	1,2,3	Pool (ensemble) homogêneo e heterogêneo. Regras de Fusão. Algoritmos de Bagging, Boosting, Random Forest. Exercícios	Em aula	4h
04/05/23				
08/05/23	1,2,3	Avaliação Somativa 03: Trabalho Prático em Grupo (Pool)	Em aula	4h
11/05/23		Aprendizagem não supervisionada. Agrupamento. Algoritmo K-Means. Índice silhueta. Exercícios		
15/05/23	1,2,3	Deep Learning. Redes Neurais Convolucionais. Redes Pré-Treinadas - uso como extrator de features e Fine Tuning. Exercícios	Em aula	4h
18/05/23				
22/05/23	1,2,3	Redes Recorrentes. RNN e LSTM (Long Short-Term Memory). Exercícios	Em aula	4h
25/05/23				
29/05/23	1,2,3	Exercícios Práticos usando modelos profundos (Deep Learning) e Redes Recorrentes.	Em aula	4h



01/06/23		Exercícios		
05/06/23	1,2,3	Avaliação Somativa 04: Trabalho Prático em Grupo (Deep Learning)	Em aula / TDE	4h / 8:30h
08/06/23				
12/06/23	1,2,3	Avaliação Somativa 05: Prova Individual (Deep Learning)	Em aula	4h
15/06/23				
19/06/23	1,2,3	Feedback coletivo sobre os trabalhos e provas. <b>Atividade de Recuperação.</b> Instruções para	Em aula	4h
22/06/23		Exame Final.		
26/06/23	De acordo com a necessidade de cada estudante	Semana estendida de recuperação (Exame Final)	Em aula	---
<b>Total</b>				80h

\*Sugerir 3 Trabalhos

- AM
- Fusão (Pool)
- Deep

Sugerir 2 Provas

- AM (Conceitos e Análise)
- Deep Learning (Conceitos e Analises)

## 8. Referências

Todas atividades contarão com o apoio de material preparado pelo professor sob a forma de slides, exercícios implementados em linguagem de programação durante as aulas e disponibilizados no ambiente virtual de aprendizagem, assim como referências para livros e artigos científicos publicados em conferências e revistas especializadas na área.

Os livros apresentados como básicos podem ser consultados na biblioteca da PUCPR pelos estudantes como fonte complementar:

#### Básica

- Russel S. J., Norvig P., Inteligência Artificial, Editora Campus, 2013.
- R. O. Duda, P. E. Hart, D. G. Stork. Pattern Classification and Scene Analysis, 2nd edition, Wiley-Interscience, 2001.
- Faceli, K., Lorena, A.C., Gama, J. & Carvalho, A.C.P.L.F, Inteligência Artificial – Uma Abordagem de Aprendizado de Máquina, LTC, 2021 (E-Books).
- LENZ, Maikon Lucian et al. Fundamentos de aprendizagem de máquina. Porto Alegre: SAGAH, 2020. E-Book (Inteligência artificial).

#### Complementar

- Data Science Academy. Deep Learning Book, 2022. Disponível em: <<https://www.deeplearningbook.com.br/>>. Acesso em: 01 Março 2023.
- Bishop, C. M. Pattern Recognition and Machine Learning. Springer, 2006.
- T. M. Mitchell. Machine Learning. McGraw–Hill Science/Engineering/Math, 432 p., ISBN 0070428077, 1997.
- COHEN, P. R. Empirical methods for artificial intelligence. The MIT Press, 1995.
- NILSSON, N. J. Artificial intelligence: a new synthesis. Morgan Kaufmann Publishers, Inc., 1998.

#### 9. Acessibilidade\*\*

Não houve necessidade de adaptação.

#### 10. Adaptações para práticas profissionais\*\*

Não houve necessidade de adaptação.

\*\* conforme nota técnica conjunta número 17/2020 CGLNRS/DPR/SERES/SERES